



Más allá del chatbot: LLMs como sistemas inteligentes

Reasoning, Tool Use y la Arquitectura de los Agentes Autónomos



El paradigma actual: Un cerebro en una cubeta


Ya sabemos construir un modelo alineado. Pero el modelo aislado es un ente estático.



El muro del Transformer: Por qué el modelo solo no basta

Limitación Inherente		Solución Sistémica
Conocimiento Estático / Desactualizado	▶	Recuperación Externa (RAG)
Incapacidad Aritmética y de Cómputo exacto	▶	Invocación de Herramientas (Tools)
Miopía en Tareas Largas	▶	Planificación Global (Planning)
Ventana de Contexto Finita	▶	Gestión de Memoria (Episódica/Semántica)
Pasividad Absoluta	▶	Ejecución de Acciones (APIs)


RAG: El primer componente del sistema



Axiomas de RAG:


1. El modelo NO aprende nuevos pesos.
2. Toda la magia ocurre mutando el contexto temporalmente.

Tool Calling: El modelo como selector estocástico




Inducción de Razonamiento: Chain of Thought (Wei et al. 2022)

Standard Prompting




CoT Prompting



Insight: Razonar en LLMs es un acto probabilístico: emitir tokens intermedios altera el estado atencional del Transformer, condicionando matemáticamente una conclusión correcta.

Diferenciación Crítica: Reasoning vs. Planning


Reasoning (Local)



Definición: Resolver el siguiente paso lógico de manera secuencial. Trazas internas (CoT).

Ejemplo: Resolver un teorema matemático paso a paso.


Planning (Global)



Definición: Descomposición de tareas abstractas, evaluación de estados futuros y corrección de ruta.

Ejemplo: Orquestar la reserva completa de unas vacaciones complejas.


Test-Time Compute: Nuevas Scaling Laws



Cambio de Paradigma:


- Históricamente escalábamos el Pre-training.
- Hoy escalamos la Búsqueda en Inferencia.

La Anatomía de un Agente Autónomo



Definición: Un sistema que recibe un objetivo, itera decidiendo acciones, observa el entorno, ajusta su plan y converge al objetivo.

Orquestación: El Harness es más importante que el Framework



Insight: El Agente no es el modelo neuronal. Es este programa determinista subyacente que lo envuelve y lo orquesta.

Evaluación de Sistemas Estocásticos

Evaluación Clásica - Modelos




Un benchmark estático ya no alcanza.

Evaluación Sistémica - Agentes

✓ Task Success Rate
Éxito end-to-end del objetivo.


87.5% ↗




⌚ Loop Latency

Tiempo total de ida y vuelta del sistema.

350 ms




Tool Accuracy




P: 92% | R: 89%

Precisión y Recall en la invocación de la API.




Cost Analysis
& Traceability

\$0.12 | 12.5K Tokens




Consumo de tokens en razonamiento y retries.


Destilación de Razonamiento: Viabilidad a escala



Resultado: Modelos eficientes que exhiben habilidades lógicas sorprendentes sin el costo de inferencia gigantesco.

El horizonte de expansión





En cinco años, entrenar Transformers será una commodity. Orquestar y evaluar sistemas agenticos alrededor de ellos será el trabajo central del Computer Scientist moderno.