


# 1. SFT: EL CIMIENTO DE LA INSTRUCCIÓN

El primer paso crítico para convertir un modelo "base" (predictor de tokens) en un "asistente".

- **Dataset:** Pares curados de [Instrucción, Respuesta].
- **Objetivo:** Maximizar la probabilidad de la respuesta humana ideal.
- **Resultado:** El modelo aprende el formato de chat y la obediencia básica.



## 2. LIMITACIONES: ¿POR QUÉ SFT NO BASTA?



### Efecto Loro

El modelo imita la forma, pero no necesariamente la veracidad o la ética detrás de los datos.



### Alucinaciones

En su afán por complacer al humano (mimicry), inventa datos con una seguridad absoluta.



### Rigidez

Es difícil definir "una única respuesta perfecta" para preguntas abiertas o creativas.

# 3. ALINEACIÓN: EL FRAMEWORK DE LAS 3 "H"

*Buscamos modelos que operen bajo principios, no solo bajo imitación.*



## **Helpful (Útil)**

Resuelve la tarea del usuario con eficiencia y contexto adecuado.



## **Honest (Honesto)**


Evita fabricar información y admite cuando no conoce la respuesta.




## **Harmless (Inofensivo)**

Detecta y se niega a generar contenido tóxico, sesgado o peligroso.

## 4. EL PIPELINE CLÁSICO DE RLHF



## 5. EL "JUEZ": REWARD MODEL (RM)



Para alinear, necesitamos un "profesor" automático que sepa qué respuesta es mejor que otra.

- **Ranking:** Los humanos no puntúan del 1-10, sino que eligen la mejor de dos opciones ( $A > B$ ).
- **Escalar:** El RM convierte esas preferencias en un valor numérico (recompensa).

## 6. OPTIMIZACIÓN DE POLÍTICA (PPO)

Es la fase donde el modelo "practica" generar miles de respuestas y el Reward Model lo castiga o premia.

$$L(\theta) = E_t [ \min ( r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t ) ]$$

La función de pérdida PPO asegura que el modelo mejore sin alejarse drásticamente de lo que ya sabía (KL divergence penalty).

# 7. LA FRICCIÓN TÉCNICA DE RLHF



## Inestabilidad

Entrenar PPO es un "ballet" matemático difícil de estabilizar.



## Costo de VRAM

Requiere cargar 4 modelos en memoria: Policy, Value, Reference y Reward.



## Lentitud

El muestreo online durante el entrenamiento consume días de cómputo.

## 8. DPO: LA VÍA DIRECTA

**Direct Preference Optimization** elimina la necesidad de un Reward Model y de algoritmos de refuerzo complejos.

DPO trata la alineación como una simple tarea de clasificación: "Aumenta la probabilidad de la respuesta elegida y disminuye la de la rechazada".





## 9. COMPARATIVA: RLHF VS DPO

| Característica    | RLHF (PPO)                            | DPO                             |
|-------------------|---------------------------------------|---------------------------------|
| Modelo Recompensa | Explícito (Necesita un modelo extra)  | Implícito (Integrado en el LLM) |
| Estabilidad       | Baja (Muy sensible a hiperparámetros) | Alta (Es una pérdida convexa)   |
| Eficiencia        | Lento (Inferencia en el loop)         | Rápido (Similar a SFT estándar) |

# 10. ¿QUÉ ELEGIR EN 2026?

## **DPO + SFT**

Es el estándar actual para la mayoría de los casos de uso empresariales debido a su facilidad de despliegue y resultados competitivos.

## **RLHF (Online)**

Sigue siendo superior para tareas de razonamiento extremo (matemáticas, código) donde el feedback debe ser dinámico.

## 11. EL FUTURO: SCALABLE OVERSIGHT

"A medida que los modelos superan la capacidad de evaluación humana, la alineación se hará mediante IA supervisando a otras IAs (Constitutional AI)."


# ¿Preguntas?

Cheat Sheet de apoyo disponible en los materiales de clase.

---

Presentación generada para Revisión de Clase LLMs | Junio 2026

# IMAGE SOURCES



[https://genmind.ch/content/2025/01/fine\\_tuning.jpg](https://genmind.ch/content/2025/01/fine_tuning.jpg)

Source: [genmind.ch](https://genmind.ch)

---



[https://images.ctfassets.net/ajq04g7mm40b/1G01aKgZmBbLbxpknIcoNs/e12cb33ae9686a9c4ce36b765f89c8eb/Untitled\\_design\\_\\_1\\_.png](https://images.ctfassets.net/ajq04g7mm40b/1G01aKgZmBbLbxpknIcoNs/e12cb33ae9686a9c4ce36b765f89c8eb/Untitled_design__1_.png)

Source: [irisagent.com](https://irisagent.com)

---



<https://blob-info.com/assets/img/slime-mold-maze-diy.jpg>

Source: [blob-info.com](https://blob-info.com)

---



<https://www.quantamagazine.org/wp-content/uploads/2022/12/A1alignment-byJamesOBrien-Lede-scaled.webp>

Source: [www.quantamagazine.org](https://www.quantamagazine.org)

---